

Homework III – Group 041

(ist106322, ist106157)

I. Pen-and-paper

Homework N° 3:

I. Pen-and-Paper

$$\phi(y_1, y_2) = y_1 \times y_2$$

1. OLS

$$f(x) = z = w_0 + w_1 y_1 + w_2 y_2$$

$$w = (X^T X)^{-1} X^T z$$

$$w_0 = 1$$

nesta cadeia de aprendizagem

$$X = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 3 \\ 1 & 3 & 2 \\ 1 & 3 & 3 \\ 1 & 2 & 4 \end{pmatrix}$$

$$z = \begin{pmatrix} 1,25 \\ 7,0 \\ 2,7 \\ 3,2 \\ 5,5 \end{pmatrix}$$

norma dos pesos:

$$\|\bar{w}\| = \sqrt{w_1^2 + w_2^2}$$

$$\phi = \begin{pmatrix} 1 & 1 \times 1 \\ 1 & 1 \times 3 \\ 1 & 3 \times 2 \\ 1 & 3 \times 3 \\ 1 & 2 \times 4 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 3 \\ 1 & 6 \\ 1 & 9 \\ 1 & 8 \end{pmatrix}$$

Então ao assumir uma nova parametrização: $w = (\phi^T \phi)^{-1} \phi^T z$

$$w = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 3 & 6 & 9 & 8 \end{pmatrix}_{2 \times 5} \begin{pmatrix} 1 & 1 \\ 1 & 3 \\ 1 & 6 \\ 1 & 9 \\ 1 & 8 \end{pmatrix}_{5 \times 2}^{-1} \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 3 & 6 & 9 & 8 \end{pmatrix}_{2 \times 5} \begin{pmatrix} 1,25 \\ 7,0 \\ 2,7 \\ 3,2 \\ 5,5 \end{pmatrix}_{5 \times 1}$$

$$\begin{matrix} \text{calc.} \\ = \end{matrix} \begin{pmatrix} 5 & 27 \\ 27 & 191 \end{pmatrix}_{2 \times 2}^{-1} \begin{pmatrix} 19,65 \\ 117,25 \end{pmatrix}_{2 \times 1} \begin{matrix} \text{calc.} \\ \simeq \end{matrix} \begin{pmatrix} 3,31593 \\ 0,11372 \end{pmatrix}_{2 \times 1} \begin{matrix} \rightarrow w_0 \\ \rightarrow w_1 \end{matrix}$$

$$f(x_1, x_2) = w_0 + w_1 \phi(x_1, x_2) = w_0 + w_1 x_1 x_2 = 3,31593 + 0,11372 x_1 x_2$$

$$\text{norma dos pesos: } \|\bar{w}\| = \sqrt{3,31593^2 + 0,11372^2} \simeq 3,31788$$

Homework III – Group 041

(ist106322, ist106157)

2. Ridge regression

penalty factor = $\lambda = 1$

$$W = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T z \quad \lambda = 1$$

norma dos pesos:

$$\|\tilde{w}\| = \sqrt{w_1^2 + w_2^2}$$

$$\lambda I = \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = 1 \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$W = \left(\begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 3 & 6 & 9 & 8 \end{pmatrix}_{2 \times 5} \begin{pmatrix} 1 & 1 \\ 1 & 3 \\ 1 & 6 \\ 1 & 9 \\ 1 & 8 \end{pmatrix}_{5 \times 2} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right)^{-1} \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 3 & 6 & 9 & 8 \end{pmatrix} \begin{pmatrix} 1,25 \\ 7,0 \\ 2,7 \\ 3,2 \\ 5,5 \end{pmatrix} = \text{calc.}$$

$$= \left(\begin{pmatrix} 5 & 27 \\ 27 & 191 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right)^{-1} \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 3 & 6 & 9 & 8 \end{pmatrix} \begin{pmatrix} 1,25 \\ 7,0 \\ 2,7 \\ 3,2 \\ 5,5 \end{pmatrix} = \text{calc.}$$

$$\text{calc.} = \begin{pmatrix} 6 & 27 \\ 27 & 192 \end{pmatrix}_{2 \times 2}^{-1} \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 3 & 6 & 9 & 8 \end{pmatrix}_{2 \times 5} \begin{pmatrix} 1,25 \\ 7,0 \\ 2,7 \\ 3,2 \\ 5,5 \end{pmatrix}_{5 \times 1} = \text{calc.} = \begin{pmatrix} 1,81809 \\ 0,32376 \end{pmatrix} \rightarrow \begin{matrix} w_0 \\ w_1 \end{matrix}$$

$$f(x_1, x_2) = w_0 + w_1 \phi(x_1, x_2) = w_0 + w_1 x_1 x_2 = 1,81809 + 0,32376 x_1 x_2$$

norma dos pesos: $\|\tilde{w}\| = \sqrt{1,81809^2 + 0,32376^2} = 1,84669$

Comparando a norma dos coeficientes obtidos com a regularização e sem, podemos observar como:

$$\|\tilde{w}\|_{OLS} > \|\tilde{w}\|_{ridge}$$

A regressão *Ridge* teve como resultados menores coeficientes, quando comparado com o modelo *OLS*. Isto era expectável, tendo em conta que o modelo *Ridge* adiciona um termo de penalização (neste caso de 1), sendo este responsável pela diminuição dos maiores coeficientes. Adicionalmente, para variáveis que têm pouco ou nenhum efeito no resultado, o fator de penalização também reduz os seus coeficientes. Portanto a regularização mantém todas as variáveis e enfatiza as com maior importância e as menos significativas são desvalorizadas. Como consequência, haverá uma melhoria na capacidade de generalização e menor propensão a grandes variações nos outputs provocadas por pequenas mudanças nos inputs. Do modelo

Homework III – Group 041

(ist106322, ist106157)

OLS, por outro lado, ao não utilizar a regularização, já resultam coeficientes com um valor absoluto mais elevado, e pode ajustar-se excessivamente aos dados de treino, especialmente quando há multicolinearidade, isto é, quando duas ou mais variáveis estão fortemente correlacionadas. Em tais situações, o modelo *OLS* tende a atribuir coeficientes muito grandes para tentar ajustar pequenas variações entre estas variáveis, o que pode levar a *overfitting*. Este modelo corre o risco de capturar as "noisy features" durante o treino, e pode ficar demasiado complexo para fazer uma generalização equilibrada. Como tal, podemos concluir como a regularização procura simplificar o modelo e melhorar a sua generalização como também prevenir o *overfitting*.

3.

D	y1	y2	y num
x6	2	2	0,7
x7	1	2	1,1
x8	5	1	2,2

compare the train and test RMSE of the 2 models in 1) and 2)

On teste,

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum (y_{num} - y'_i)^2}$$

$$x'_{new} = f(x_{new}) = w_0 + w_1 x_{new1} + \dots + w_m x_{newm}$$

Modelo 1: OLS

$$x'_6 = f(x_6) = f(2,2) = 3,31593 + 0,11372 \times 2 \times 2 = 3,77081$$

$$x'_7 = f(x_7) = f(1,2) = 3,31593 + 0,11372 \times 1 \times 2 = 3,54337$$

$$x'_8 = f(x_8) = f(5,1) = 3,31593 + 0,11372 \times 5 \times 1 = 3,88453$$

$$x'_1 = f(x_1) = f(1,1) = 3,31593 + 0,11372 \times 1 \times 1 = 3,42965$$

$$x'_2 = f(x_2) = f(1,3) = 3,31593 + 0,11372 \times 1 \times 3 = 3,65709$$

$$x'_3 = f(x_3) = f(3,2) = 3,31593 + 0,11372 \times 3 \times 2 = 3,09825$$

$$x'_4 = f(x_4) = f(3,3) = 3,31593 + 0,11372 \times 3 \times 3 = 4,33941$$

$$x'_5 = f(x_5) = f(2,4) = 3,31593 + 0,11372 \times 2 \times 4 = 4,22569$$

	y1	y2	y num	y' num	(y num - y' num)
x1	1	1	1,25	3,42965	-2,17965
x2	1	3	7,0	3,65709	3,34291
x3	3	2	2,7	3,09825	-1,29825
x4	3	3	3,2	4,33941	-1,13941
x5	2	4	5,5	4,22569	1,27431
x6	2	2	0,7	3,77081	-3,07081
x7	1	2	1,1	3,54337	-2,44337
x8	5	1	2,2	3,88453	-1,68453

Homework III – Group 041

(ist106322, ist106157)

$$RMSE_{train} = \sqrt{MSE_{train}} = \sqrt{\frac{1}{5} \left((-2,17965)^2 + (3,34291)^2 + (-1,29825)^2 + (-1,13944)^2 + (1,27431)^2 \right)} = \sqrt{1,10669915} \approx 2,02650$$

$$RMSE_{test} = \sqrt{MSE_{test}} = \sqrt{\frac{1}{3} \left((-3,07081)^2 + (-2,44337)^2 + (-1,68453)^2 \right)} = \sqrt{6,079100778} \approx 2,46560$$

Modelo 2: Ridge regression

$$x_1' = f(x_1) = f(1,1) = 1,81809 + 0,32376 \times 1 \times 1 = 2,14185$$

$$x_2' = f(x_2) = f(1,3) = 1,81809 + 0,32376 \times 1 \times 3 = 2,78937$$

$$x_3' = f(x_3) = f(3,2) = 1,81809 + 0,32376 \times 3 \times 2 = 3,76065$$

$$x_4' = f(x_4) = f(3,3) = 1,81809 + 0,32376 \times 3 \times 3 = 4,73193$$

$$x_5' = f(x_5) = f(2,4) = 1,81809 + 0,32376 \times 2 \times 4 = 4,40817$$

$$x_6' = f(x_6) = f(2,2) = 1,81809 + 0,32376 \times 2 \times 2 = 3,11313$$

$$x_7' = f(x_7) = f(1,2) = 1,81809 + 0,32376 \times 1 \times 2 = 2,46561$$

$$x_8' = f(x_8) = f(5,1) = 1,81809 + 0,32376 \times 5 \times 1 = 3,43689$$

	x_1	x_2	y_{num}	y'_{num}	$(y_{num} - y'_{num})$
x_1	1	1	1,25	2,14185	-0,89185
x_2	1	3	7,0	2,78937	4,21063
x_3	3	2	2,7	3,76065	-1,06065
x_4	3	3	3,2	4,73193	-1,53193
x_5	2	4	5,5	4,40817	1,09183
x_6	2	2	0,7	3,11313	-2,41313
x_7	1	2	1,1	2,46561	-1,36561
x_8	5	1	2,2	3,43689	-1,23689

Homework III – Group 041

(ist106322, ist106157)

$$\begin{aligned}
 RMSE_{train} &= \sqrt{MSE_{train}} = \sqrt{\frac{1}{5} \left((-0,89185)^2 + (4,21063)^2 + (-1,06065)^2 \right.} \\
 &\quad \left. + (-1,53193)^2 + (1,09183)^2 \right) = \sqrt{4,637736423} \simeq 2,15354 \\
 \\
 RMSE_{test} &= \sqrt{MSE_{test}} = \sqrt{\frac{1}{3} \left((-2,41313)^2 + (-1,36561)^2 + (-1,23689)^2 \right)} \\
 &= \sqrt{3,072661314} \simeq 1,75290 \\
 \\
 &\text{Comparando os resultados:}
 \end{aligned}$$

Após determinar os valores de *RMSE* para cada modelo, podemos observar que o erro de treino para o modelo que utiliza *OLS* é inferior ao erro de teste respetivo, enquanto para o modelo de regressão *Ridge* se verifica o contrário.

O facto de que o erro para o conjunto de treino do modelo *OLS* é inferior ao erro para o conjunto de teste, indica que o modelo faz *overfitting* aos dados de treino, isto é, adequa-se aos dados conhecidos, mas não é tão capaz de estimar resultados para observações novas. Efetivamente, esta conclusão está de acordo com o esperado para o modelo *OLS*, já que é sabido que este modelo tem tendência a apresentar *overfitting*, sendo bastante flexível e não restringido pela regularização.

Por outro lado, para o modelo *Ridge*, constatamos que o erro para o conjunto de treino é superior ao erro para o conjunto de teste. Neste caso, a regularização reduz o problema de *overfitting* do *OLS*, sendo que a penalização introduzida torna o modelo menos complexo, permitindo uma melhor generalização e capacidade de avaliar novas observações. Note-se ainda que apesar de o erro de treino da regressão *Ridge* ser ligeiramente superior ao de treino do *OLS*, o erro de teste é significativamente inferior, o que corrobora a expectativa de que o *Ridge* apresente uma melhor capacidade de generalização. Mais uma vez, estes resultados concordam com o expectável, visto que a regularização é uma forma de reduzir o risco de *overfitting*, forçando a diminuição dos coeficientes com valores maiores e tornando o modelo mais simples e com menor variância.

Homework III – Group 041

(ist106322, ist106157)

4. MLP → Multilayer Perceptron

one stochastic gradient descent update → the observation is x_1

⊕1 de output
↓
classificação

$$W[1] = \begin{bmatrix} 0,1 & 0,1 \\ 0,1 & 0,2 \\ 0,2 & 0,1 \end{bmatrix}$$


$$b[1] = \begin{bmatrix} 0,1 \\ 0 \\ 0,1 \end{bmatrix}$$

$$W[2] = \begin{bmatrix} 1 & 2 & 2 \\ 1 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

$$b[2] = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

Rede:
2 = corado
3 = corado
1 = corado

3 = corado
3 = corado
2 = corado




Função de ativação

$$\text{softmax}(z_c^{\text{out}}) = \frac{e^{z_c^{\text{out}}}}{\sum_{l=1}^{|c|} e^{z_l^{\text{out}}}}$$

Homework III – Group 041

(ist106322, ist106157)



1) Propaga  o:

$$z[i] = w[i]x[i-1] + b[i], \quad x[i] = f(z[i])$$

$$z[1] = w[1]x[0] + b[1] = \begin{bmatrix} 0,1 & 0,1 \\ 0,1 & 0,2 \\ 0,2 & 0,1 \end{bmatrix}_{3 \times 2} \begin{bmatrix} 1 \\ 1 \end{bmatrix}_{2 \times 1} + \begin{bmatrix} 0,1 \\ 0 \\ 0,1 \end{bmatrix}_{3 \times 1} = \begin{bmatrix} 0,2 \\ 0,3 \\ 0,3 \end{bmatrix} + \begin{bmatrix} 0,1 \\ 0 \\ 0,1 \end{bmatrix}$$

$$= \begin{bmatrix} 0,3 \\ 0,3 \\ 0,4 \end{bmatrix}$$

$x[1] = z[1]$ (pois n o h  fun  o de ativa  o nos "hidden layers").

$$\sum_{j=1}^n z[j]$$

$$= \begin{bmatrix} 0,3 / (2^{0,3} + 2^{0,3} + 2^{0,4}) \\ 0,3 / (2^{0,3} + 2^{0,3} + 2^{0,4}) \\ 0,4 / (2^{0,3} + 2^{0,3} + 2^{0,4}) \end{bmatrix} = \begin{bmatrix} 0,3220634544 \\ 0,3220634544 \\ 0,3553365456 \end{bmatrix}$$

$$z[2] = w[2]x[1] + b[2] = \begin{bmatrix} 1 & 2 & 2 \\ 1 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 0,3 \\ 0,3 \\ 0,4 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1,7 \\ 1,3 \\ 1,2 \end{bmatrix}$$

ReLU

$$\begin{bmatrix} 2,7 \\ 2,3 \\ 2 \end{bmatrix}$$

Homework III – Group 041

(ist106322, ist106157)

$$n[2] = \text{softmax}(z[2]) = \frac{e^{z[2]}}{\sum_{l=1}^{|C|} e^{z[2]_l}} = \begin{bmatrix} \text{softmax}(2,7) \\ \text{softmax}(2,3) \\ \text{softmax}(2) \end{bmatrix} =$$

$$= \begin{bmatrix} \frac{e^{2,7}}{e^{2,7} + e^{2,3} + e^2} \\ \frac{e^{2,3}}{e^{2,7} + e^{2,3} + e^2} \\ \frac{e^2}{e^{2,7} + e^{2,3} + e^2} \end{bmatrix}$$

$$\approx \begin{bmatrix} 0,4614876234 \\ 0,309344405 \\ 0,2291679717 \end{bmatrix}$$

2) Propagação para trás: $\begin{cases} 1^\circ \text{ calcular as derivadas} \\ 2^\circ \text{ deltas} \\ 3^\circ \text{ regra} \end{cases}$

$$\text{Derivadas: } \frac{\partial z[i]}{\partial w[i]} = n[i-1] \quad \frac{\partial z[i]}{\partial n[i-1]} = w[i]$$

$$\frac{\partial z[i]}{\partial b[i]} = 1 \quad \frac{\partial n[i]}{\partial z[i]} = ?$$

Na função softmax, todas as saídas estão interconectadas por meio do denominador que é a soma das exponenciais de todas as entradas. Alterar uma entrada afeta tanto a própria saída (caso $i=j$) quanto as saídas das outras entradas (caso $i \neq j$).

Homework III – Group 041

(ist106322, ist106157)

Calcular a derivada parcial de $\text{softmax}(z_i)$ em relação a z_j , ou seja,

$$\frac{\partial \text{softmax}(z_i)}{\partial z_j}$$

Caso $i = j$:

$$\frac{\partial \text{softmax}(z_i)}{\partial z_i} = \frac{(e^{z_i})' \cdot \left(\sum_{l=1}^m e^{z_l} \right) - e^{z_i} \cdot \left(\sum_{l=1}^m e^{z_l} \right)'}{\left(\sum_{l=1}^m e^{z_l} \right)^2}$$

$$* = \frac{e^{z_i} \left(\sum_{l=1}^m e^{z_l} \right) - e^{z_i} \cdot e^{z_i}}{\left(\sum_{l=1}^m e^{z_l} \right)^2} = \frac{e^{z_i} \left(\sum_{l=1}^m e^{z_l} - e^{z_i} \right)}{\left(\sum_{l=1}^m e^{z_l} \right)^2}$$

$$= \frac{e^{z_i}}{\left(\sum_{l=1}^m e^{z_l} \right)^2} \cdot \left(\frac{\sum_{l=1}^m e^{z_l}}{\sum_{l=1}^m e^{z_l}} - \frac{e^{z_i}}{\left(\sum_{l=1}^m e^{z_l} \right)} \right) =$$

$$= \text{softmax}(z_i) \cdot (1 - \text{softmax}(z_i))$$

* $\left(\sum_{l=1}^m e^{z_l} \right)'_{z_i} = e^{z_i}$ pois apenas o termo correspondente a z_i contribui para a derivada de $\sum_{l=1}^m e^{z_l}$, os outros termos que não dependem de z_i , têm derivada = 0.

Caso $i \neq j$:

$$\frac{\partial \text{softmax}(z_i)}{\partial z_j} = \frac{\cancel{e^{z_i}}' \cdot \left(\sum_{l=1}^m e^{z_l} \right) - e^{z_i} \cdot \left(\sum_{l=1}^m e^{z_l} \right)'}{\left(\sum_{l=1}^m e^{z_l} \right)^2} =$$

$$= \frac{-e^{z_i} \cdot e^{z_j}}{\left(\sum_{l=1}^m e^{z_l} \right)^2} = -\text{softmax}(z_i) \cdot \text{softmax}(z_j)$$

Homework III – Group 041

(ist106322, ist106157)

Ent o:

$$\frac{\partial \pi[i]}{\partial z[j]} = \begin{cases} \text{softmax}(z[i]) \cdot (1 - \text{softmax}(z[i])) & \text{se } i = j \\ -\text{softmax}(z[i]) \cdot \text{softmax}(z[j]) & \text{se } i \neq j \end{cases}$$

ento 

$$\frac{\partial \pi[i]}{\partial z[i]} = \text{softmax}(z[i]) \cdot (1 - \text{softmax}(z[i]))$$

para $i = 2$
se $i \neq 2$ n o   fun  o
de ativa  o e $\pi[i] = z[i]$,
logo

$$\frac{\partial \pi[i]}{\partial z[i]} = \frac{\partial z[i]}{\partial z[i]} = 1$$

Guia:

$$- \sum_{i=1}^N \sum_{l=1}^{|C|} \pi_l^{(i)} \log(X_l^{\text{out}}(i)) = E$$

m amostras (pointing to N)
n classes (pointing to |C|)
true label for sample i, class l (pointing to $\pi_l^{(i)}$)

Homework III – Group 041

(ist106322, ist106157)

ii) resultado de derivada softmax com entropia cruzada

$$\delta[2] = \frac{\partial E}{\partial x[2]} \circ \frac{\partial x[2]}{\partial z[2]} = x[2] - t = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

$t = \text{target} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$

$$= \begin{bmatrix} 0,4614876234 \\ 0,3093444049 \\ 0,2291679716 \end{bmatrix} - \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0,4614876234 \\ -0,6906555951 \\ 0,2291679716 \end{bmatrix}$$

glademark

$$\delta[1] = \left(\frac{\partial z[2]}{\partial x[1]} \right)^T \cdot \delta[2] \circ \frac{\partial x[1]}{\partial z[1]} = (w[2]^T \cdot \delta[2]) \circ \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

$$= \left(\begin{pmatrix} 1 & 2 & 2 \\ 1 & 2 & 1 \\ 1 & 1 & 1 \end{pmatrix}^T \cdot \delta[2] \right) \cdot \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \left(\begin{pmatrix} 1 & 1 & 1 \\ 2 & 2 & 1 \\ 2 & 1 & 1 \end{pmatrix} \cdot \begin{pmatrix} 0,4614876234 \\ -0,6906555951 \\ 0,2291679716 \end{pmatrix} \right)$$

$$\circ \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \times 10^{-10} \\ -0,2291679718 \\ 0,4614876233 \end{pmatrix} \circ \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \times 10^{-10} \\ -0,2291679718 \\ 0,4614876233 \end{pmatrix}$$

Atualiza:

$$b[2]^{\text{new}} = b[2]^{\text{old}} - \eta \frac{\partial E}{\partial b[2]} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} - 0,1 \left(b[2] \cdot \frac{\partial z[2]}{\partial b[2]} \right)$$

$$= \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} - 0,1 \begin{pmatrix} 0,4614876234 \\ -0,6906555951 \\ 0,2291679716 \end{pmatrix} = \begin{pmatrix} 0,95385 \\ 1,06907 \\ 0,97708 \end{pmatrix}$$

Homework III – Group 041

(ist106322, ist106157)

$$w[2]^{new} = w[2]^{old} - \eta \frac{\partial E}{\partial w[2]} = \begin{bmatrix} 1 & 2 & 2 \\ 1 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix} - 0,1 \begin{pmatrix} 0,13 \\ 0,13 \\ 0,14 \end{pmatrix}$$

$$\left(\frac{\partial z[2]}{\partial w[2]} \right)^T = \begin{bmatrix} 1 & 2 & 2 \\ 1 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix} - 0,1 \begin{pmatrix} 0,4614876234 \\ -0,6906555951 \\ 0,2291679716 \end{pmatrix} \cdot \begin{bmatrix} 0,13 & 0,13 & 0,14 \end{bmatrix} =$$

$$= \begin{bmatrix} 0,98616 & 1,98616 & 1,98154 \\ 1,02072 & 2,02072 & 1,02762 \\ 0,99312 & 0,99312 & 0,99083 \end{bmatrix}$$

$$b[1]^{new} = b[1]^{old} - \eta \frac{\partial E}{\partial b[1]} = \begin{bmatrix} 0,1 \\ 0 \\ 0,1 \end{bmatrix} - 0,1 \begin{pmatrix} 0,1 \\ 0 \\ 0,1 \end{pmatrix} \cdot \frac{\partial z[1]}{\partial b[1]} =$$

$$= \begin{bmatrix} 0,1 \\ 0 \\ 0,1 \end{bmatrix} - 0,1 \begin{pmatrix} -1 \times 10^{-10} \\ -0,2291679718 \\ 0,4614876233 \end{pmatrix} = \begin{pmatrix} 0,10000 \\ 0,12292 \\ 0,05385 \end{pmatrix}$$

$$w[1]^{new} = w[1]^{old} - \eta \frac{\partial E}{\partial w[1]} = \begin{bmatrix} 0,1 & 0,1 \\ 0,1 & 0,2 \\ 0,2 & 0,1 \end{bmatrix} - 0,1 \begin{pmatrix} 0,1 \\ 0,1 \\ 0,2 \end{pmatrix} \cdot \left(\frac{\partial z[1]}{\partial w[1]} \right)^T =$$

$$= \begin{bmatrix} 0,1 & 0,1 \\ 0,1 & 0,2 \\ 0,2 & 0,1 \end{bmatrix} - 0,1 \begin{pmatrix} -1 \times 10^{-10} \\ -0,2291679718 \\ 0,4614876233 \end{pmatrix} \cdot \begin{bmatrix} 1 & 1 \end{bmatrix} =$$

$$= \begin{pmatrix} 0,10000 & 0,10000 \\ 0,12292 & 0,22292 \\ 0,15385 & 0,05385 \end{pmatrix}$$